

리벨리온 NPU 기반 LG AI EXAONE 모델 서빙을 위한 아키텍처 수준의 성능 최적화 전략 보고서

인공지능 기술의 패러다임이 거대 언어 모델(LLM)을 중심으로 급격히 재편됨에 따라, 이를 뒷받침하는 하드웨어 인프라의 효율성은 기업의 경쟁력을 결정짓는 핵심 요소가 되었다. 특히 한국의 인공지능 생태계에서 LG AI Research의 엑사온(EXAONE) 모델 시리즈와 리벨리온(Rebellions)의 신경망 처리 장치(NPU)의 결합은 하드웨어와 소프트웨어를 아우르는 '소버린 AI(Sovereign AI)' 인프라 구축의 중추적 사례로 평가받는다.¹ 엑사온 3.0 및 K-EXAONE과 같은 고성능 모델을 리벨리온의 아톰(ATOM™) 및 아톰-맥스(ATOM™-Max) 시스템에서 서빙하기 위해서는 단순한 모델 포팅을 넘어, NPU 고유의 아키텍처 특성을 고려한 정교한 최적화 전략이 요구된다.²

본 보고서는 리벨리온 NPU 머신에서 엑사온 모델을 서빙할 때 성능을 극대화하기 위한 기술적 준비 과정과 구체적인 실행 방안을 상세히 분석한다. 이를 위해 아톰 아키텍처의 데이터 흐름 최적화, RBLN SDK를 통한 컴파일 및 양자화 전략, 그리고 vLLM-RBLN 플러그인을 활용한 분산 서빙 기법을 중점적으로 다룬다.⁴

리벨리온 NPU 하드웨어 아키텍처와 엑사온 모델의 정합성

성능 최적화의 첫 번째 단계는 실행 대상인 하드웨어의 물리적 구조와 모델의 연산 특성 사이의 상관관계를 이해하는 것이다. 리벨리온의 아톰 아키텍처는 범용 GPU와 달리 추론 성능과 에너지 효율성에 최적화된 설계를 취하고 있다.²

ATOM™-Max 아키텍처의 물리적 구성

아톰-맥스는 대규모 인공지능 추론을 위해 설계된 랙 스케일 인프라의 핵심 유닛이다.⁷ 각 아톰-맥스 카드는 5개의 칩으로 구성된 멀티 칩 모듈 방식을 채택하고 있으며, 여기에는 4개의 아톰 NPU 다이와 이들을 통합 관리하는 중앙 PCIe 컨트롤러가 포함된다.⁶ 이러한 구조는 호스트 시스템과의 통신 효율을 극대화하며, 단일 PCIe Gen5 x16 인터페이스를 통해 1 TB/s에 달하는 대역폭을 제공한다.⁶

항목	아톰-맥스(ATOM™-Max) 상세 사양
피크 성능 (INT8)	카드당 512 TOPS ⁶
피크 성능 (FP16)	카드당 128 TFLOPS ⁶
온칩 SRAM 용량	NPU당 64MB (총 256MB) ⁴
인터페이스	PCIe Gen5 x16 ⁶
열 설계 전력 (TDP)	350W ⁶
네트워크 인프라	400 GB/s RDMA Fabric (Pod 구성 시) ⁷

아키텍처 측면에서 아톰 NPU는 8개의 강력한 신경망 엔진(Neural Engine)을 탑재하고 있으며,

이를 정교하게 설계된 메모리 계층 구조가 지원한다.⁴ 특히 64MB의 대용량 온칩 SRAM은 LLM 추론 과정에서 빈번하게 발생하는 중간 텐서와 가중치 데이터를 외부 DRAM 호출 없이 처리할 수 있게 함으로써 지연 시간을 획기적으로 단축한다.⁴

LG EXAONE 모델 시리즈의 구조적 특징

LG의 엑사온 모델은 성능과 비용의 균형을 맞춘 7.8B 모델부터, 236B에 달하는 파라미터를 보유한 K-EXAONE까지 다양한 라인업을 갖추고 있다.¹⁰ 이들 모델은 하드웨어 최적화 관점에서 다음과 같은 핵심적인 아키텍처 요소를 포함한다.

1. **MoE(Mixture-of-Experts) 구조 (K-EXAONE):** 2360억 개의 전체 파라미터 중 추론 시에는 230억 개(약 10%)의 파라미터만을 활성화한다.¹² 이는 NPU의 메모리 대역폭을 효율적으로 사용하면서도 거대 모델의 성능을 유지할 수 있게 한다.¹³
2. 하이브리드 어텐션(**Hybrid Attention**): 엑사온은 슬라이딩 윈도우 어텐션(SWA)과 글로벌 어텐션(GA)을 3:1 비율로 혼합하여 사용한다.¹² SWA는 고정된 128 토큰 윈도우 내에서만 연산을 수행하여 메모리 점유율을 낮추고, GA는 긴 문맥 유지에 기여한다.⁵
3. 다중 토큰 예측(**MTP, Multi-Token Prediction**): 학습 시 보조 모듈로 사용된 MTP는 추론 시 자기 투사적 디코딩(Self-Speculative Decoding)을 가능하게 하여 처리량을 약 1.5배 향상시킨다.¹¹

이러한 모델 특성은 리벨리온 NPU의 연산 엔진 분포 및 메모리 관리 방식과 긴밀하게 연계되어야 최적의 서빙 성능을 낼 수 있다.³

기술적 준비: 모델 컴파일 및 최적화 파이프라인

리벨리온 NPU에서 엑사온 모델을 성공적으로 실행하기 위해서는 RBLN SDK를 통한 다단계 컴파일 과정과 정밀한 양자화 전략이 필수적이다.⁴

RBLN 컴파일러를 통한 그래프 최적화

RBLN 컴파일러는 PyTorch나 TensorFlow와 같은 프레임워크에서 정의된 모델을 NPU 전용 실행 파일(.rbln)로 변환하는 역할을 수행한다.⁴ 이 과정은 프론트엔드와 백엔드로 나뉜다.

프론트엔드 컴파일러는 딥러닝 모델을 중간 표현(IR)으로 추상화하고, 이 과정에서 연산자 융합(Operator Fusion), 중복 노드 제거, 심볼릭 형상 추론(Symbolic Shape Inference)을 수행한다.⁹ 예를 들어, 엑사온의 트랜스포머 블록 내 레이어 정규화(Layer Norm)와 선형 레이어(Linear Layer)를 하나의 커널로 결합함으로써 데이터 이동 비용을 최소화한다.⁴

백엔드 컴파일러는 최적화된 IR을 아톰 하드웨어의 신경망 엔진에 매핑한다.⁹ 이 단계에서는 아톰의 온칩 SRAM 크기에 맞춘 타일링(Tiling) 기법이 적용된다.³ 엑사온 모델은 레이어의 크기가 매우 크기 때문에, 컴파일러는 가중치 데이터를 적절한 크기로 분할하여 SRAM에 로드하고 연산을 수행한 후 결과를 DRAM으로 돌려보내는 명령 스트림(Command Stream)을 생성한다.⁴ 특히 프로덕션 환경에서의 최적화를 위해 프리필(Prefill)과 디코딩(Decode) 그래프의 분리 컴파일이 권장된다.¹⁴ 프리필 단계는 입력 프롬프트를 한꺼번에 처리하므로 연산 집약적인 특성을 가지며, 디코딩 단계는 토큰을 하나씩 생성하므로 메모리 대역폭에 민감하다.¹⁶ RBLN SDK는 이 두 단계를 별도의 그래프로 최적화하여 각각에 맞는 특화 커널(FlashAttention 및 KV Caching 커널)을 적용함으로써 전체 지연 시간을 단축한다.¹⁴

양자화(Quantization) 전략 및 정밀도 제어

NPU의 연산 능력을 극대화하기 위해 엑사온 모델을 INT8 또는 FP8 형식으로 양자화하는 과정이 수반된다.⁴ 리벨리온 아톰 NPU는 INT8 연산 시 FP16 대비 4배 높은 연산 처리량(128 TOPS vs 32 TFLOPS)을 제공하므로, 양자화는 성능 향상의 핵심 변수다.⁴

양자화 과정에서는 **scale**과 **zero_point**를 사용하여 부동 소수점 값을 8비트 정수 공간으로 매핑한다.¹⁵ 엑사온과 같은 대규모 모델의 경우 가중치와 활성화 함수(Activation)의 데이터 분포가 비대칭적일 수 있으므로, 비대칭 양자화(Asymmetric Quantization)를 적용하여 정밀도 손실을 최소화한다.¹⁵

양자화 기법	특징 및 장점	적용 대상 (엑사온 기준)
INT8 PTQ	학습 후 양자화, 데이터 교정(Calibration) 사용 ¹⁵	모델 가중치 및 선형 연산 ⁴
FP8	추론 장치에서 에너지 효율과 정밀도 균형 ¹⁷	소프트맥스(Softmax) 등 민감 연산 ¹⁷
INT4/FP4	극단적인 메모리 압축, 가중치 전용 양자화 ¹⁴	초거대 가중치 행렬 ¹⁴
블록 양자화	텐서를 블록으로 나누어 각기 다른 스케일 적용 ¹⁸	KV 캐시 최적화 ⁵

리벨리온 SDK는 지능형 정밀도 제어 기능을 통해 모델의 각 레이어별로 최적의 정밀도를 자동으로 할당한다.¹⁴ 예를 들어, 오차에 민감한 주의집중(Attention) 점수 계산은 FP16을 유지하고, 연산량이 많은 피드포워드 네트워크(FFN)는 INT8로 변환하여 성능과 정확도 사이의 최적점을 찾는다.¹⁴

실행 단계: 고성능 서빙 프레임워크 구축

컴파일된 모델을 실제 서비스 환경에 배포할 때는 리벨리온이 제공하는 전용 서빙 스택과 최신 LLM 최적화 기법을 결합하여 실행 효율을 높여야 한다.³

vLLM-RBLN 플러그인 활용

리벨리온은 오픈소스 LLM 서빙 프레임워크인 vLLM의 기능을 NPU 하드웨어에서 구현하기 위해 **vllm-rbln** 플러그인을 제공한다.³ 이 플러그인은 vLLM의 상위 수준 API를 유지하면서 하위 실행 경로를 RBLN 런타임에 최적화된 방식으로 재설계한다.⁵

vllm-rbln의 핵심 기능 중 하나는 연속 배치(Continuous Batching)이다.¹⁶ 기존의 정적 배치 방식은 배치 내의 모든 요청이 완료될 때까지 새로운 요청을 받지 못해 하드웨어 자원이 유휴 상태가 되는 문제가 있었다.¹⁹ 연속 배치는 각 요청이 완료되는 즉시 새로운 요청을 배치에 투입하여 NPU의 가동률을 극대화한다.¹⁶ 이는 엑사온 3.0 7.8B와 같이 초당 요청 처리수(QPS)가 중요한 시나리오에서 특히 효과적이다.¹⁴

또한, 플러그인은 자동 프리픽스 캐싱(Automatic Prefix Caching)을 지원한다.¹⁴ 동일한 시스템 프롬프트나 긴 문서 내용을 반복적으로 사용하는 다중 턴 대화 시나리오에서, 이미 연산된 KV 캐시를 재사용함으로써 중복 연산을 제거하고 첫 번째 토큰 생성 시간(TTFT)을 획기적으로

줄인다.⁶

페이징된 어텐션(PagedAttention)과 메모리 관리

엑사온 모델은 최대 256K 토큰의 문맥 길이를 지원하므로, 서빙 시 메모리 관리가 가장 큰 병목 현상이 된다.¹¹ 리벨리온은 이를 해결하기 위해 운영체제의 가상 메모리 관리 기법을 차용한

PagedAttention 커널을 하드웨어 수준에서 구현하였다.⁵

기존 방식은 최대 시퀀스 길이에 맞춰 메모리를 미리 할당하여 fragmentation(파편화)과 낭비가 심했으나, PagedAttention은 KV 캐시를 작은 블록 단위로 나누어 필요할 때마다 동적으로 할당한다.⁵ 리벨리온 NPU 런타임은 이 블록들을 하드웨어의 메모리 계층에 최적화하여 배치하며, 인덱스 회전 및 윈도우 추적을 내부적으로 관리한다.³ 특히 엑사온의 슬라이딩 윈도우 어텐션(SWA)과 결합될 때, 활성 윈도우 외부의 데이터를 효율적으로 제거하고 새로운 데이터를 덮어쓰는 인플레이스(In-place) 회전 방식을 사용하여 메모리 압박을 최소화한다.³

분산 서빙 및 MoE 최적화

K-EXAONE과 같은 236B 모델은 단일 NPU 카드의 메모리 용량을 초과하므로, 리벨리온의 분산 시스템 프레임워크인 RSD(Rebellions Scalable Design)를 통한 다중 노드 서빙이 필요하다.⁵

RSD는 텐서 병렬성(Tensor Parallelism)과 전문가 병렬성(Expert Parallelism)을 동시에 지원한다.¹⁴ 엑사온의 MoE 블록을 처리할 때, 각기 다른 NPU 노드에 분산된 128개의 전문가들에게 토큰을 라우팅해야 한다.³ 이때 발생하는 노드 간 통신 부하는 400 GB/s의 고대역폭 RDMA 패브릭을 통해 해소된다.⁷

병렬화 기법	엑사온 모델 적용 방식	하드웨어 지원 요소
텐서 병렬성 (TP)	대형 행렬 연산을 4~8개의 NPU로 분할 실행 ¹³	PCIe Gen5 x16 내부 스위치 ²⁰
전문가 병렬성 (EP)	MoE 전문가들을 여러 노드에 나누어 배치 ³	400G 데이터 스위치 및 RDMA ⁷
프리필/디코딩 분리	문맥 생성과 토큰 생성을 별도 노드에서 수행 ³	RSD 분산 스케줄러 ⁵

특히 MoE 모델의 병목 현상인 All-to-All 통신을 최적화하기 위해, 리벨리온은 통신 볼륨을 무손실로 줄이는 투사적 전문가 그룹화(Speculative Expert Grouping) 기술을 연계하여 처리량을 개선한다.²¹

시스템 수준의 심화 최적화 방안

컴파일과 서빙 프레임워크 설정 외에도, 실제 운영 환경에서 성능을 극대화하기 위한 시스템 하위 계층의 튜닝 요소들이 존재한다.⁴

RBLN 프로파일러를 통한 성능 분석 및 튜닝

최적화의 핵심은 병목 지점을 정확히 파악하는 것이다. RBLN SDK에 포함된 프로파일러를 활성화하면(예: activate_profiler=True), 모델 실행 과정에서의 상세 타임라인을 확보할 수 있다.⁶ 프로파일링 결과에서 주목해야 할 부분은 Task DMA와 Neural Engine Cluster 간의 중첩

여부이다.⁶ 만약 신경망 엔진이 연산을 수행하는 동안 다음 레이어의 가중치를 불러오는 DMA 전송이 완료되지 않는다면 하드웨어가 유틸 상태에 빠지게 된다.⁶ 이를 해결하기 위해 컴파일러 설정에서 비동기 실행 동작(Asynchronous Execution Behavior)을 강화하거나, 장치 상주 텐서(Device-resident Tensors) 기능을 활성화하여 호스트와 장치 간의 불필요한 데이터 이동을 제거해야 한다.²⁰

또한, 특정 연산이 NPU에서 지원되지 않아 CPU로 넘어가는 호스트 폴백(Host Fallback) 현상을 모니터링해야 한다.⁶ 엑사온 모델의 복잡한 활성화 함수나 정규화 연산이 폴백될 경우 전체 지연 시간이 급격히 증가하므로, 해당 연산자를 NPU 전용 커널로 대체하거나 컴파일러의 연산자 지원 범위를 확인하여 모델 코드를 일부 수정하는 작업이 필요할 수 있다.⁴

열 관리 및 전력 최적화

아톰-맥스와 같은 고밀도 시스템은 장시간 고부하 추론 시 발열 문제가 발생할 수 있다.²⁰ 리벨리온 드라이버는 온도가 75°C에 도달하면 서멀 스로틀링(Thermal Throttling)을 가동하여 성능을 일부 제한하고, 85°C에서는 보호를 위해 작동을 중지한다.²⁰

성능 최적화 관점에서는 이러한 스로틀링이 발생하지 않도록 P-state 기능을 활용하여 전력 효율을 관리하고, 유틸 시간 동안 DRAM 저전력 모드(LPM)를 활성화하여 전체 시스템의 열 부하를 낮추는 정책을 적용해야 한다.²⁰ 이는 결과적으로 일정한 추론 성능을 안정적으로 유지하는 데 기여한다.²⁰

결론 및 실무적 제언

리벨리온 NPU 머신에서 LG AI Research의 엑사온 모델을 서빙하는 것은 한국의 하드웨어와 소프트웨어 기술력을 결집한 고도의 엔지니어링 작업이다.¹ 성능을 최적화하기 위해서는 아톰 하드웨어의 SRAM 중심 구조를 이해하고, 이를 최대한 활용할 수 있는 컴파일 및 서빙 전략을 수립해야 한다.³

기술적 준비 측면에서는 엑사온의 MoE 및 하이브리드 어텐션 구조를 고려한 RBLN 컴파일러 튜닝과 정밀한 INT8 양자화가 우선되어야 한다.⁹ 실행 단계에서는 vllm-rbln 플러그인을 통해 연속 배치와 PagedAttention을 적용하고, K-EXAONE과 같은 대규모 모델의 경우 RSD를 활용한 RDMA 기반 분산 서빙 환경을 구축하는 것이 필수적이다.⁵

이러한 최적화 과정을 통해 구축된 '소버린 산업용 AI 스택'은 기존 GPU 기반 시스템 대비 탁월한 전력 효율성과 비용 절감 효과를 제공하며, 건설, 제조, 서비스 등 다양한 산업 현장에서 실제적인 가치를 창출하는 기반이 될 것이다.²⁴ 실무자들은 RBLN 프로파일러를 통한 지속적인 모니터링과 하드웨어 스펙에 맞춘 배치 전략 조정을 통해 각 산업 현장의 요구 사항에 부합하는 최적의 AI 추론 환경을 완성해야 한다.⁴

참고 자료

1. Upstage's \$400M Sovereign AI Funding — The Korean Data Question | Pebblous, 5월 12, 2026에 액세스, <https://blog.pebblous.ai/report/upstage-national-fund-2026-05/en/>
2. Rebellions: The Korean Company to Watch in 2026? - News - All About Circuits, 5월 12, 2026에 액세스,

- <https://www.allaboutcircuits.com/news/rebellions-the-korean-company-to-watch-in-2026/>
3. LLM Serving with NPU: Re-engineered, Built for Scale and Efficiency - Rebellions AI, 5월 12, 2026에 액세스, <https://rebellions.ai/llm-serving-with-npu/>
 4. Developers - Rebellions AI, 5월 12, 2026에 액세스, <https://rebellions.ai/developers/>
 5. LLM Serving with NPU: - Rebellions, 5월 12, 2026에 액세스, https://rebellions.ai/wp-content/uploads/2026/03/Rebellions_Whitepaper_EN_v.08.pdf
 6. Introducing rebellions ATOM™-MAX - The official SqueezeBits Tech ..., 5월 12, 2026에 액세스, <https://blog.squeezebits.com/introducing-atom-max-npu>
 7. ATOM™-Max Pod | Rebellions, 5월 12, 2026에 액세스, https://rebellions.ai/wp-content/uploads/2025/08/RebellionsATOM-Max-Pod_brochure_v1.0_EN.pdf
 8. ATOM™-Max POD - Rebellions AI, 5월 12, 2026에 액세스, <https://rebellions.ai/rebellions-product/atom-max-pod/>
 9. Rebellions' Software Stack, 5월 12, 2026에 액세스, https://rebellions.ai/wp-content/uploads/2024/08/WhitePaper_Issue2_ATOM_SoftwareStack.pdf
 10. EXAONE 3.0 7.8B Instruction Tuned Language Model - LG AI연구원, 5월 12, 2026에 액세스, https://www.lgresearch.ai/data/upload/tech_report/ko/EXAONE_3.0_Technical_Report.pdf?ref=maginate.com
 11. Official repository for K-EXAONE built by LG AI Research - GitHub, 5월 12, 2026에 액세스, <https://github.com/LG-AI-EXAONE/K-EXAONE>
 12. K-EXAONE Technical Report - LG AI연구원, 5월 12, 2026에 액세스, https://www.lgresearch.ai/data/cdn/upload/K-EXAONE_Technical_Report.pdf
 13. LGAI-EXAONE/K-EXAONE-236B-A23B · Hugging Face, 5월 12, 2026에 액세스, <https://huggingface.co/LGAI-EXAONE/K-EXAONE-236B-A23B>
 14. vLLM Hands-on Workshop WrapUp - Rebellions, 5월 12, 2026에 액세스, <https://rebellions.ai/vllm-hands-on-workshop-wrapup/>
 15. Quantize ONNX models | onnxruntime, 5월 12, 2026에 액세스, <https://onnxruntime.ai/docs/performance/model-optimizations/quantization.html>
 16. Continuous batching from first principles - Hugging Face, 5월 12, 2026에 액세스, https://huggingface.co/blog/continuous_batching
 17. FP8 versus INT8 for efficient deep learning inference - arXiv, 5월 12, 2026에 액세스, <https://arxiv.org/pdf/2303.17951>
 18. Working with Quantized Types — NVIDIA TensorRT, 5월 12, 2026에 액세스, <https://docs.nvidia.com/deeplearning/tensorrt/latest/inference-library/work-quantized-types.html>
 19. PagedAttention vs Continuous Batching vs vLLM vs SGLang — A Practical Breakdown | by varun rao | Python in Plain English, 5월 12, 2026에 액세스, <https://python.plainenglish.io/pagedattention-vs-continuous-batching-vs-vllm-vs-sglang-a-practical-breakdown-4c19cc9e21c0>
 20. Release Notes - - RBLN SDK USER GUIDE -, 5월 12, 2026에 액세스, https://docs.rbln.ai/v0.8.2/supports/release_note.html

21. Communication Efficient Parallel MoE Inference with Speculative Token and Expert Pre-scheduling - arXiv, 5월 12, 2026에 액세스,
<https://arxiv.org/html/2503.04398v1>
22. 릴리스 노트 - - RBLN SDK USER GUIDE - - Rebellions, 5월 12, 2026에 액세스,
https://docs.rbln.ai/ko/supports/release_note.html
23. 2026 Marks Debut of Korean AI Chips, KRW 9.9 Trillion Push | DBR -
동아비즈니스리뷰, 5월 12, 2026에 액세스,
https://dbr.donga.com/kfocus/view/en/article_no/1264
24. mellerikat, 5월 12, 2026에 액세스, <https://mellerikat.com/en/partners/>